

Prediksi Intensitas Emosi Berbasis Teks: Studi Komparasi Pendekatan Klasik TF-IDF Ridge Regression dan Deep Learning DistilBERT

Felis Eren Cristi Milala
Departemen Informatika
Universitas Diponegoro
Semarang, Indonesia
feliseren@students.undip.ac.id

Clarency Christy Pasaribu
Departemen Informatika
Universitas Diponegoro
Semarang, Indonesia
clarencypasaribu@students.undip.ac.id

Abstract— Memahami intensitas emosi teks secara kontinu merupakan tantangan krusial dalam Pengolahan Bahasa Alami. Penelitian ini akan mengevaluasi dua pendekatan untuk memprediksi skor intensitas emosi menggunakan dataset Emoint Wasa yang mencakup emosi *anger*, *fear*, *joy*, dan *sadness*. Setelah tahapan *pre-processing* untuk membersihkan teks, eksperimen akan membandingkan model mesin klasik dengan model *deep learning*. Model mesin klasik dibangun menggunakan ekstraksi fitur *Term Frequency Inverse Document Frequency* tingkat kata dan karakter yang digabungkan dengan algoritma *Ridge Regression*. Sebagai pembandingnya, model bahasa DistilBERT dievaluasi melalui tahapan pelatihan lanjutan. Perbandingan kedua model ini memberikan gambaran mengenai kelebihan dan keterbatasan masing-masing pendekatan dalam tugas prediksi skor emosi. Penelitian ini menunjukkan bahwa regresi teks dapat digunakan untuk mengukur intensitas emosi secara numerik pada data media sosial.

Keywords— *Text Regression, Emotion Intensity, Term Frequency Inverse Document Frequency, Ridge Regression, DistilBERT.*

I. PENDAHULUAN

Interaksi manusia di dalam platform media sosial telah bertransformasi menjadi arsip digital yang menyimpan spektrum psikologis manusia secara real-time. Sementara itu, sebagian besar studi analisis afektif tradisional masih bertujuan untuk mengategorikan teks ke dalam satu emosi diskret, yang berarti penelitian-penelitian ini hanya mengklasifikasikan setiap teks ke dalam kategori emosi tertentu, bukan memberikan penilaian tentang seberapa kuat penulis terpengaruh. Frustrasi yang ringan dan amarah yang meledak-ledak, misalnya, keduanya digabungkan ke dalam kelas “marah”, meskipun bobot psikologisnya sangat berbeda. Oleh karena itu, diperlukan pengukuran intensitas emosi dalam skala kontinu [0, 1] untuk menggambarkan tingkat emosi dari pengguna secara lebih detail.

Eksresi emosi yang terlihat di Twitter atau X, yang masih sangat besar, dapat menciptakan banyak peluang. Ini bisa mencakup hal-hal seperti memantau kesehatan mental masyarakat, menganalisis sentimen produk dengan lebih mendalam, dan bahkan membuat sistem untuk memberi tahu kita tentang krisis psikologis lebih awal. Strategis ini akan lebih berguna jika sistem NLP bisa mengukur seberapa kuat emosi seseorang, bukan hanya membaginya ke dalam kategori.

Tantangan ini mendapatkan perhatian yang cukup serius dari komunitas riset NLP internasional melalui kompetisi SemEval-2018 *Task 1: Affect in Tweets* [3]. Kompetisi

tersebut menyediakan *benchmark* standar yang digunakan untuk memprediksi intensitas emosi pada tweet dengan anotasi berbasis *Best-Worst Scaling*, sebuah metode anotasi terbukti dapat menghasilkan label dengan reliabilitas yang tinggi antar-anotator. Pendekatan yang telah diusulkan dari tim partisipan SemEval, termasuk ke dalam sistem berbasis jaringan saraf rekuren dan mengkombinasikannya dengan fitur leksikal afektif [4], ini menunjukkan bahwa tugas regresi emosi memerlukan representasi semantik yang kaya dan dapat melampaui kemampuan model berbasis frekuensi kata sederhana.

Perkembangan dari arsitektur Transformer [10] dan model berbasis BERT [1] dapat memberikan perubahan yang besar dalam pemrosesan teks karena mampu memahami konteks kata dalam sebuah kalimat dengan lebih baik. Kemampuan ini secara teoritik sangat relevan untuk tugas regresi intensitas emosi yang membutuhkan pemahaman semantik secara halus pada tingkat kalimat secara menyeluruh.

Penelitian ini memiliki tujuan untuk melakukan pengujian hipotesis tersebut secara empiris melalui perbandingan sistematis antara dua pendekatan : (1) model baseline ekstraksi fitur leksikal menggunakan kombinasi TF-IDF yang berbasis kata dan karakter dan digabungkan dengan *Ridge Regression*, serta (2) model *deep learning* melalui *fine-tuning* DistilBERT [2], yaitu sebuah varian BERT yang lebih efisien secara komputasional. Dengan dataset Emoint-Wasa2017 yang digunakan sebagai *benchmark*, penelitian ini memiliki tujuan untuk dapat melihat sejauh mana pemahaman konteks pada model mampu meningkatkan akurasi prediksi intensitas emosi dibandingkan dengan pendekatan *bag-of-words* tradisional.

II. TINJAUAN PUSTAKA

Ada berbagai jenis algoritma representasi teks yang digunakan dalam NLP, dan trennya bergerak dari penggunaan metode statistik ke pendekatan berurutan berbasis konteks. TF-IDF (Term Frequency-Inverse Document Frequency) [8] adalah model perolehan yang umum digunakan dalam klasifikasi teks. Saat ini, TF-IDF terbatas karena representasi teks yang diberikannya bersifat statis dan masih belum mampu mengoversi kemunculan kata berdasarkan konteks kalimat. TF-IDF dengan model pembelajaran mesin reguler seperti Support Vector Machine atau Ridge Regression cukup bagi sebagai model dasar [5], [6], terutama ketika ukuran dataset terbatas.

Untuk mengatasi keterbatasan representasi berbasis kata, maka dikembangkan metode *word embedding* seperti Word2Vec dan GloVe. Metode ini dapat menunjukkan

hubungan antar kata dalam bentuk vektor yang dapat menangkap makna semantik dengan lebih baik dibandingkan TF-IDF. Namun, representasi tersebut masih bersifat statis karena satu kata hanya memiliki satu representasi vektor tanpa melihat konteks penggunaannya dalam kalimat. Perkembangan penting dalam NLP terjadi ketika Vaswani et al. Memperkenalkan arsitektur Transformer dengan mekanisme *self-attention* [10]. Mekanisme ini membuat model memahami hubungan antar kata dengan melihat semua konteks kalimat secara bersamaan. Dengan pendekatan tersebut, model dapat menghasilkan representasi teks yang lebih kontekstual dan efektif.

Arsitektur Tranformer kemudian dikembangkan lebih lanjut oleh Devlin et al. Melalui model BERT [1]. BERT menggunakan proses pra-pelatihan dua arah sehingga model dapat memahami konteks kata berdasarkan keseluruhan kalimat. Pendekatan ini membuat BERT dapat memahami makna kalimat dengan lebih baik pada berbagai tugas NLP, termasuk analisis emosi dan sentimen. Untuk analisis sentimen dan deteksi emosi, kemampuan ini terbukti sangat efektif [12], karena emosi dalam kalimat biasanya tidak ditentukan dari satu kata saja, tetapi juga dipengaruhi oleh konteks dan hubungan antar kata dalam kalimat tersebut.

DistilBERT dikembangkan karena kebutuhan untuk menggunakan model BERT di komputer yang tidak terlalu kuat. Dengan cara khusus bernama *knowledge distillation*, DistilBERT bisa bekerja hampir sama baik dengan BERT, tapi dengan ukuran yang lebih kecil dan lebih cepat. Model ini memiliki sekitar 40% parameter yang dimiliki BERT, tapi tetap bisa memberikan hasil yang hampir sama baik dengan 97% performa BERT. Bahkan, DistilBERT bisa bekerja 60% lebih cepat daripada BERT. Hal ini sangat berguna dalam penelitian ini karena DistilBERT dapat bekerja dengan efisien tanpa mengurangi kemampuan analisis semantik yang mendalam.

Beragam penelitian telah menunjukkan bahwa model Transformer sangat efektif dalam menganalisis emosi dan sentimen. Survei komprehensif tentang deep learning untuk analisis sentimen [11] menunjukkan bahwa model berbasis attention memiliki kinerja lebih baik daripada metode tradisional. Penelitian spesifik tentang deteksi emosi menggunakan model Transformer [7], [13], [14], [15] mencatat adanya peningkatan kinerja yang signifikan, terutama pada tugas yang membutuhkan pemahaman tentang sarkasme, metafora, dan ekspresi emosi yang tidak langsung. Selain itu, penggunaan RoBERTa [9] sebagai pengembangan dari BERT dengan strategi pra-pelatihan yang lebih baik juga menunjukkan bahwa kualitas dan jumlah data pra-pelatihan mempengaruhi kemampuan model dalam memahami konteks dan nuansa emosi pada teks.

Berdasarkan literatur yang ada, model Tranformer cenderung memberikan hasil yang lebih baik dibandingkan metode yang berdasarkan statistik leksikal, terutama pada tugas NLP yang membutuhkan pemahaman konteks. Pada data media sosial yang banyak menggunakan bahasa informal, singkatan, dan ekspresi kontekstual, perbedaan hasil tersebut diperkirakan menjadi semakin terlihat.

III. METODOLOGI PENELITIAN

A. Deskripsi Dataset dan Pengumpulan Data

Dataset yang digunakan untuk penelitian ini adalah dataset Emoint-Wassa2017 [3], sebuah *benchmark* standar

yang pertama kali diperkenalkan dalam kompetisi SemEval-2018 *Task 1: Affect in Tweets*. Dataset ini dipilih karena memiliki kualitas anotasi yang tinggi menggunakan metode *Best-Worst Scaling* serta datasetnya tersedia secara publik yang dapat diakses melalui repositori GitHub. Dataset ini mencakup empat dimensi emosi: *anger*, *fear*, *joy*, dan *sadness*, dengan skor intensitas kontinu berada dalam rentang [0, 1].

Distribusi data secara keseluruhan dari dataset adalah 3.613 sampel untuk data *train*, 347 sampel untuk data *development*, dan 3.142 sampel untuk data *test*. Pada data *train*, distribusi setiap kelas emosi tidak seimbang dengan *fear* memiliki sampel terbesar yaitu 1.147 *tweet*, lalu diikuti *anger* sebanyak 857 *tweet*, *joy* sebanyak 823 *tweet*, dan *sadness* sebanyak 786 *tweet*. Statistik deskriptif dari skor menunjukkan bahwa distribusi yang relatif rata sekitar 0,495 dan standar deviasi 0,190, ini menunjukkan bahwa sampel tidak mendominasi dataset dengan intensitas yang ekstrem.

TABLE I. DISTRIBUSI SAMPLE DATASET EMOINT-WASSA2017

<i>Split</i>	<i>Anger</i>	<i>Fear</i>	<i>Joy</i>	<i>Sadness</i>
Train	857	1147	823	786
Dev	84	110	79	74
Test	760	995	714	673

B. Preprocessing Teks

Tahap *preprocessing* dilakukan untuk membersihkan teks *tweet* sebelum digunakan pada fase pelatihan model. Fungsi *clean_tweet* yang digunakan mengikuti sejumlah operasi regex berurutan. Fungsi html awal mengganti karakter entitas HTML seperti & dengan nilai literalnya menggunakan fungsi `html.unescape()`. Kedua, mengubah seluruh teks menjadi huruf kecil untuk meminimalkan kekeliruan leksikal yang dihasilkan oleh variasi kapitalisasi. Ketiga, untuk URL dan *mention* pengguna (yaitu @username), diganti dengan token tertentu, yaitu URL atau USER masing-masing, ini adalah prinsip *feed uniqueness*. Penggantian ini disengaja: *mention* dan tautan merupakan sinyal kontekstual yang berguna, *tweet* yang ditujukan kepada institusi sering kali berisi keluhan dan memiliki intensitas negatif yang lebih tinggi. Keempat, tagar dipertahankan dengan menghapus tanda pagar (#) dan membuatnya tersedia bagi model agar dapat mempertahankan informasi semantiknya. Terakhir, karakter non-alfanumerik yang tidak mengandung makna akan dihapus, dengan pengecualian untuk simbol tanda baca dasar seperti !, ?, ., ,.

Untuk kedua model, teks yang sudah dibersihkan akan diperkaya dengan informasi kategori emosi menggunakan format template: "[EMOTION] {label_emosi} [TWEET] {teks_bersih}". Menambahkan token [EMOTION] di awal input secara eksplisit akan menambahkan informasi kelas emosi ke dalam representasi, sehingga memungkinkan model untuk belajar karakteristik linguistik yang spesifik per emosi.

C. Model Baseline : TF-IDF + Ridge Regression

Model *baseline* ini dibuat menggunakan *pipeline* dari *scikit-learn* dengan arsitektur *FeatureUnion* yang menggabungkan dua ekstraktor fitur secara paralel. Ekstraktor pertama menggunakan *Word-level TF-IDF Vectorizer* dengan rentang *n-gram* dari 1 sampai 3, jadi menghasilkan representasi mulai dari *unigram* hingga *trigram* kata. Untuk mengurangi *noise* dari kata-kata yang sangat jarang muncul, fitur dibatasi maksimal 20.000 dan hanya kata-kata yang

muncul minimal di dua dokumen saja yang akan dihitung. Lalu, menerapkan *Sublinear TF scaling* dengan penggunaan $1 + \log(\text{tf})$ sebagai bobot agar meredam dominasi dari kata-kata yang sering muncul.

Ekstraktor kedua yang digunakan adalah *Character-level TF-IDF Vectorizer* dengan rentang n-gram karakter antara 3 sampai 5. Representasi berbasis karakter ini secara tidak langsung mampu menangkap informasi morfologis, termasuk ejaan tidak baku yang sering ditemukan di Twitter, serta sufiks dan prefiks yang membawa nuansa emosional. Jika menggabungkan representasi kata dan karakter hasilnya adalah ruang fitur yang jauh lebih kaya dibandingkan jika hanya menggunakan salah satu secara terpisah.

Regressor yang dipakai adalah *Ridge Regression*, yaitu regresi linier yang menggunakan regularisasi L2. Pilihan ini didasarkan pada karakteristik ruang fitur TF-IDF yang sangat *sparse* dan mempunyai dimensi tinggi, di mana regularisasi L2 terbukti efektif untuk mencegah *overfitting* dengan cara mendistribusikan bobot secara merata. Untuk *hyperparameter alpha*, dilakukan optimasi lewat *grid search* dengan nilai-nilai {0.1, 0.3, 0.5, 1.0, 2.0, 5.0, 10.0}, dan akhirnya dipilih $\alpha=2.0$ karena memberikan korelasi pearson tertinggi di set *development* yaitu 0.4482.

D. Model Deep Learning

Model *deep learning* ini menggunakan arsitektur DistilBERT [2] yang di-*fine-tune* khusus untuk tugas regresi dengan pengaturan `num_labels=1` dan `problem_type="regression"`. Untuk tokenisasi, menggunakan *AutoTokenizer* dari *distilbert-base-uncased* dengan maksimal 96 token. Panjang ini dipilih agar bisa menampung *tweet* lengkap, termasuk token tambahan seperti [EMOTION] dan [TWEET], tanpa harus mengorbankan terlalu banyak isi konten.

Konfigurasi pelatihan dilakukan dengan menggunakan *Hugging Face Trainer API* dan beberapa parameter penting, seperti *learning rate* $2e-5$ yang memang umum dipakai untuk *fine-tuning* model BERT. Untuk *batch size*, menggunakan 16 per perangkat saat pelatihan dan 32 saat evaluasi. Selain itu, ada *weight decay* 0.01 sebagai tambahan regularisasi, dan maksimum menggunakan 6 epoch. Menerapkan mekanisme *early stopping* dengan *patience*=2 untuk menghindari *overfitting*. Lalu pada set validasi, menggunakan *Pearson correlation* sebagai metrik untuk menyeleksi model terbaik. *Mixed precision training* (fp16) diaktifkan untuk mempercepat komputasi pada GPU.

E. Metrik Evaluasi

Pemilihan metrik evaluasi disesuaikan dengan karakteristik tugas regresi kontinu. *Pearson correlation* digunakan untuk mengukur seberapa kuat hubungan linier antara prediksi dan nilai sebenarnya, sehingga menjadi metrik utama karena sesuai dengan standar penilaian SemEval-2018 [3]. Sementara itu, *Spearman correlation* menilai hubungan monoton dan lebih tahan terhadap *outlier*. MAE dan RMSE sama-sama mengukur kesalahan prediksi rata-rata secara absolut, tetapi RMSE cenderung memberikan penalti yang lebih besar untuk kesalahan yang cukup besar. Sementara itu, koefisien determinasi R^2 menjelaskan seberapa besar variansi dari target yang berhasil ditangkap oleh model.

IV. HASIL DAN ANALISIS

A. Perbandingan Performa Global

Tabel II menunjukkan perbandingan kinerja kedua model pada set pengujian. Perbedaan terbesar terlihat pada nilai *Pearson correlation*: DistilBERT mencapai 0,7401 sedangkan model TF-IDF Ridge yang hanya 0,5292, sebuah peningkatan absolut sebesar 0,2109 atau sekitar 39,8% secara relatif. Kesenjangan ini tidak hanya soal statistik. Ini juga menunjukkan perbedaan besar dalam cara kedua model memahami dan mewakili teks. Model DistilBERT tampaknya lebih baik dalam memahami teks.

TABLE II. DISTRIBUSI SAMPLE DATASET EMOINT-WASSA2017

Model	MAE	RMSE
TF-IDF + Ridge	0.1363	0.169
DistilBERT Regression	0.1052	0.1348

Mengapa pemahaman kontekstual DistilBERT menghasilkan keunggulan? Jawabannya terletak pada cara kerja self-attention [10] yang memungkinkan model untuk memahami setiap kata dalam kalimat berdasarkan konteksnya. Ambil contoh *tweet* seperti "I'm so happy I could cry". Secara harfiah, *tweet* ini mengandung kata "happy" yang memiliki makna positif, tapi juga kata "cry" yang memiliki makna negatif. Model TF-IDF akan mewakili *tweet* ini sebagai kombinasi dari kedua kata tersebut, yang menyebabkan prediksi yang salah tentang betapa bahagianya orang tersebut, karena adanya sinyal yang saling bertentangan.. DistilBERT, sebaliknya, dapat memahami bahwa dalam konteks ini "cry" bukanlah tanda kesedihan, tetapi ekspresi kebahagiaan yang sangat kuat.

Nilai R^2 dari TF-IDF adalah 0,2756 yang artinya model ini hanya bisa menjelaskan sekitar 27,6% variansi dalam skor intensitas emosi. Jadi, lebih dari 72% variasi dalam intensitas emosi tidak dapat dijelaskan oleh representasi bag-of-words. Walaupun hyperparameternya sudah diatur dengan baik, hasilnya akan tetap sama. Sebaliknya, DistilBERT berhasil meningkatkan R^2 menjadi 0,5389. Ini berarti hampir setengah dari variasi target dapat dijelaskan, tetapi masih ada ruang untuk perbaikan.

Perbedaan *Mean Absolute Error* (MAE) antara TF-IDF dan DistilBERT adalah 0,031. MAE TF-IDF adalah 0,1363, sedangkan MAE DistilBERT adalah 0,1052. Walaupun perbedaannya terlihat kecil, namun dalam konteks skor target yang hanya berkisar antara 0 dan 1, penurunan kesalahan rata-rata sebesar 22,8% memiliki dampak yang nyata. Dengan demikian, prediksi DistilBERT lebih akurat sekitar tiga satuan poin dibandingkan TF-IDF pada skala [0,1].

B. Analisis Performa per Emosi

Analisis yang didasarkan pada dimensi emosi (Tabel III) memperlihatkan pola menarik dari sudut pandang linguistik. DistilBERT secara konsisten menunjukkan hasil yang lebih baik daripada TF-IDF di semua kategori emosi yang diuji. Akan tetapi, peningkatan performanya bervariasi pada setiap emosi, yang menunjukkan bahwa setiap emosi memiliki kompleksitas representasi bahasa yang unik. Emosi yang dinyatakan secara jelas melalui kata-kata tertentu masih dapat dikenali dengan baik oleh TF-IDF, sementara emosi yang lebih konsep atau bergantung pada konteks lebih mudah dipahami oleh DistilBERT. Ini menunjukkan bahwa kemampuan DistilBERT dalam menangkap konteks dan

hubungan semantik antar kata membuatnya lebih efektif dalam mengenali nuansa emosi yang rumit dibandingkan dengan metode berbasis frekuensi kata seperti TF-IDF.

TABLE III. PERBANDINGAN PEARSON CORRELATION PER EMOSI

Emosi	TF-IDF + Ridge	DistilBERT
Anger	0.4864	0.7130
Fear	0.5952	0.7605
Joy	0.3860	0.6914
Sadness	0.6158	0.7909

Emosi sadness mencapai Pearson correlation tertinggi untuk DistilBERT (0,7910) dan juga tertinggi di antara keempat emosi pada model TF-IDF (0,6158). Fenomena ini dapat diuraikan melalui analisis ciri-ciri linguistik ekspresi kesedihan. Dalam kumpulan *tweet* berbahasa Inggris, ekspresi kesedihan cenderung memanfaatkan kosakata yang cukup konvensional dan jelas, misalnya kata-kata seperti "miss", "lost", "alone", "broken", atau "crying". Kosakata ini menunjukkan hubungan yang lebih kuat dan lebih stabil dengan tingkat kesedihan, sehingga bahkan representasi leksikal yang sederhana dapat menangkap sebagian besar variasi intensitasnya. DistilBERT selanjutnya meningkatkan kemampuan ini dengan memahami konteks pemakaiannya, contohnya membedakan antara "I miss you" yang bernilai intensitas sedang dengan "I miss you every single day" yang bernilai intensitas tinggi.

Sebaliknya, emosi *joy* memperlihatkan kinerja terendah untuk kedua model, dengan Pearson 0,6914 pada DistilBERT dan 0,3860 pada TF-IDF. Selisih sebesar 0,3054 antara TF-IDF dan DistilBERT untuk emosi *joy* juga menjadi yang teratas di antara empat emosi, menunjukkan bahwa ekspresi kebahagiaan memiliki kompleksitas linguistik tertinggi. Dari sudut pandang analisis bahasa, ungkapan *joy* di Twitter sering kali memanfaatkan berbagai bentuk hiperbola, ironi, atau gaya bahasa tidak langsung yang sangat bergantung pada konteks.

Misalnya, *tweet* seperti "This is literally the worst day ever!!!" bisa saja merupakan ungkapan ironis dari seseorang yang sebenarnya sedang bahagia karena sebuah kejadian kecil yang kurang menyenangkan, sedangkan "I can't even" bisa jadi adalah ungkapan kegembiraan yang berlebihan. Ambiguitas jenis ini hampir tidak dapat diselesaikan oleh model berbasis statistik leksikal. DistilBERT, berkat kemampuan *attention*-nya, memiliki potensi lebih tinggi untuk menangkap sinyal kontekstual ini, meskipun kinerja untuk *joy* tetap yang terendah di antara keempat emosi, mencerminkan keterbatasan kemampuan model saat ini dalam menangani ekspresi afektif yang sangat bervariasi.

Emosi *fear* (Pearson DistilBERT 0,7605) berada di urutan kedua tertinggi. Ekspresi ketakutan biasanya melibatkan kosakata yang lebih terperinci dan teratur secara semantik, sering kali disertai rujukan langsung kepada objek atau situasi yang memicu perasaan takut. Anger (Pearson 0,7130) menunjukkan pertumbuhan yang signifikan dari TF-IDF (0,4864), mencerminkan kemampuan DistilBERT dalam memahami ekspresi kemarahan yang biasanya muncul dalam bentuk instruksi, ancaman, atau penekanan linguistik yang memerlukan pemahaman kontekstual selama proses interpretasi.

C. Analisis Dinamika Pelatihan dan Risiko Overfitting

Tabel pelatihan DistilBERT menunjukkan dinamika yang harus ditafsirkan dengan cermat. Pada *epoch* 1, kehilangan pelatihan ada di angka 0,0240, lalu menurun secara signifikan menjadi 0,0065 pada *epoch* 5. Penurunan yang cepat ini menunjukkan kemampuan model yang besar dalam menyerap pola-pola dari data latih. Namun, perhatian harus difokuskan pada perilaku *validation loss*: setelah mencapai titik terendah pada *epoch* 3 (0,016869), *validation loss* mulai naik kembali menjadi 0,017923 pada *epoch* 5.

Pola perbedaan antara *training loss* dan *validation loss* ini adalah indikasi klasik dari *overfitting*. Secara spesifik, sejak *epoch* 4, model mulai "mengingat" pola-pola tertentu dari data latih yang tidak dapat diterapkan pada data baru yang belum familiar. Mekanisme *early stopping* dengan *patience* = 2 berfungsi dengan baik dalam situasi ini, memilih bobot model dari *epoch* 3 sebagai model terbaik berdasarkan metrik Pearson pada set validasi (0,7283).

Analisis ini memiliki dampak signifikan untuk penelitian mendatang. Fakta bahwa model terbaik hanya tercapai pada *epoch* ke-3 dari total 6 *epoch* yang direncanakan menunjukkan bahwa dataset Emoint dengan 3.613 sampel tergolong kecil untuk melakukan *fine-tuning* pada model Transformer berparameter besar. Metode augmentasi data, seperti *back-translation* atau parafrase yang dibantu oleh model bahasa, dapat meningkatkan kinerja dan juga memperlambat terjadinya *overfitting*. Selain itu, penerapan dropout yang lebih kuat atau regularisasi tambahan pada *layer classifier* bisa dipertimbangkan sebagai solusi.

Harus dicatat bahwa meskipun ada *overfitting* pada data pelatihan, kinerja akhir DistilBERT pada set pengujian (Pearson 0,7401) masih jauh lebih baik dibandingkan TF-IDF (0,5292). Hal ini menunjukkan bahwa kemampuan representasional DistilBERT yang kuat, meskipun dalam keadaan *overfitting* parsial, tetap dapat memberikan generalisasi yang lebih baik secara keseluruhan. Hal ini dapat dipahami karena DistilBERT menyimpan pengetahuan linguistik yang mendalam dari fase pra-pelatihan pada korpus besar, yang berperan sebagai bentuk regularisasi implisit yang sangat efektif.

V. KESIMPULAN

Penelitian ini secara empiris menunjukkan keunggulan yang jelas dari model berbasis Transformer seperti DistilBERT dibandingkan dengan pendekatan ekstraksi fitur leksikal seperti TF-IDF yang dipadukan dengan *Ridge Regression* dalam tugas regresi intensitas emosi pada teks *tweet*. Dapat dilihat peningkatan korelasi Pearson sebesar 39,8% secara relatif, disertai dengan penurunan MAE sebesar 22,8% serta hampir dua kali lipat kenaikan nilai R^2 . Semua ini secara bersama-sama menegaskan bahwa pemahaman kontekstual yang didukung mekanisme *attention* mampu menangkap nuansa semantik afektif yang pada dasarnya sulit dijangkau oleh representasi *bag-of-words*. Perbedaan performa yang paling mencolok terlihat pada emosi *joy*, di mana kompleksitas bahasa seperti ironi, hiperbola, dan ungkapan tidak langsung justru semakin menonjolkan keterbatasan model statistik leksikal.

Temuan ini ternyata mempunyai dampak yang lebih luas daripada sekadar perbandingan teknis biasa. Dari segi konsep, hasilnya justru semakin memperkuat pandangan bahwa intensitas emosi dalam bahasa manusia itu sebenarnya sangat

dipengaruhi oleh konteks dan cara penyusunannya. Jadi, saat memilih model untuk aplikasi nyata, misalnya dalam pemantauan emosi publik, analisis kepuasan pelanggan yang detail, atau sistem peringatan kesehatan mental, sebaiknya mempertimbangkan keunggulan yang ditawarkan oleh *Transformer* ini.

REFERENSI

- [1] J. Devlin, M.-W. Chang, K. Lee, dan K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," dalam Proc. NAACL-HLT 2019, Minneapolis, MN, 2019, hal. 4171–4186.
- [2] V. Sanh, L. Debut, J. Chaumond, dan T. Wolf, "DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter," arXiv:1910.01108, 2019.
- [3] S. M. Mohammad, F. Bravo-Marquez, M. Salameh, dan S. Kiritchenko, "SemEval-2018 Task 1: Affect in Tweets," dalam Proc. 12th Int. Workshop Semantic Evaluation, 2018, hal. 1–17.
- [4] C. Baziotis, A. Nikolaos, dan A. Potamianos, "NTUA-SLP at SemEval-2018 Task 1: Predicting Affect in Tweets Using Deep Neural Networks," dalam Proc. SemEval-2018, New Orleans, LA, 2018, hal. 91–100.
- [5] A. Yadav dan D. K. Vishwakarma, "A Comparison of Deep Learning and Traditional Machine Learning for Sentiment Analysis," dalam Proc. ICIINFS 2020, hal. 1–6.
- [6] M. Arulmurugan, R. Kumar, dan S. Satheesh, "Comparative Analysis of Machine Learning and Deep Learning Approaches for NLP," Int. J. Comput. Appl., vol. 975, hal. 8887, 2020.
- [7] H. Acheampong, C. Nunoo-Mensah, dan W. Chen, "Emotion Analysis using Transformer Models," Comput. Intell., vol. 37, no. 3, hal. 1224–1247, 2021.
- [8] G. Salton dan C. Buckley, "Term-weighting approaches in automatic text retrieval," Inf. Process. Manag., vol. 24, no. 5, hal. 513–523, 1988.
- [9] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, dan V. Stoyanov, "RoBERTa: A Robustly Optimized BERT Pretraining Approach," arXiv:1907.11692, 2019.
- [10] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, dan I. Polosukhin, "Attention Is All You Need," Adv. Neural Inf. Process. Syst., vol. 30, 2017.
- [11] S. Zhang, X. Deng, J. Bian, dan K. Liu, "Deep Learning for Sentiment Analysis: A Survey," Wiley Interdiscip. Rev. Data Min. Knowl. Discov., vol. 8, no. 4, e1253, 2018.
- [12] A. Ghosh dan T. Veale, "Sentiment Analysis using Bidirectional Encoder Representations from Transformers," dalam Proc. NAACL 2021, hal. 301–312.
- [13] A. Chatterjee, K. N. Narahari, M. Joshi, dan P. Agrawal, "Emotion Detection in Text using Deep Learning," dalam Proc. NAACL 2019 Workshop, Minneapolis, 2019.
- [14] Z. Li, H. Zhu, M. Lu, dan M. Peng, "Transformer-based Emotion/Sentiment Study," Sci. Rep., vol. 13, art. 7057, 2023.
- [15] D. Gupta dan A. Ekbal, "Transformer-based Models for Text Emotion Recognition," dalam Proc. AAAI 2021 Workshop on Affective Content Analysis, 2021.